

Contents

主流大语言模型综合性能评价与选型研究1

摘要1

1 问题重述与研究框架1

2 数据、假设与符号2

3 数据清洗与指标筛选2

4 CRITIC—TOPSIS 综合评价4

5 三类场景评价7

6 性能—成本与工程效率8

7 稳健性与规律分析11

8 模型评价与局限11

9 结论12

10 复现说明12

11 数据来源与可追溯性12

主流大语言模型综合性能评价与选型研究

摘要

本文针对公开资料条件下的大语言模型综合评价问题，建立“数据冻结—口径清洗—指标筛选—客观赋权—场景评价—成本效益—稳健性检验”的完整流程。以 2026 年 8 月 17 日为统一数据截面，从 9 个候选模型中确定 Kimi K3、GPT-5.6 Sol、Claude Fable 5、Claude Opus 4.8、GPT-5.5 与 GLM-5.2 为研究池，并冻结高难推理、长文本、代码、专业任务、多模态和文档理解等 9 项指标。研究不自行调用模型测试，也不填补未公开成绩。

首先用覆盖率、方差及 Pearson/Spearman 相关分析筛选指标，再采用 CRITIC 确定客观权重，以 TOPSIS 对 5 个完整样本排序。Claude Fable 5、Kimi K3、GPT-5.6 Sol 分列综合排名前三；GLM-5.2 仅有 4/9 项同口径成绩，因此只作局部对照。其次，将客观权重与透明的场景偏好各按 50% 组合，得到科研长文本、日常对话和代码开发排序：Kimi K3 在科研长文本场景第一，在另两类场景第二。最后，以 100 万输入 token 与 20 万输出 token 为标准负载，Kimi K3 与 Claude Fable 5 构成性能—API 成本 Pareto 前沿；在可兼容效率子样本中，Kimi 的部署综合分最高。现有公开数据不含同硬件、同精度、同批量条件下的焦耳/token 或千瓦时指标，故本文不虚构计算能耗，而将 API 成本作为直接落地成本、将 TTFT/吞吐/总延迟作为兼容范围内的工程效率证据。熵权法与 36 组权重扰动表明主要结论总体稳健。

关键词：大语言模型；CRITIC；TOPSIS；场景评价；Pareto 前沿；敏感性分析

1 问题重述与研究框架

题目要求解决三类问题：一是从公开且可核验的 Benchmark 中建立完整指标体系、筛选关键指标、合理赋权并评价主流模型，重点分析 Kimi K3；二是针对科研长文本、日常通用对话和代码开发建立场景化排序并解释差异；三是综合性能、使用成本与计算消耗，分析性能—落地成本效益并给出预算约束下的选择。

技术路线为：公开数据审计 → 固定可比 cohort → 缺失与单位检查 → 相关性和覆盖率筛选 → CRITIC 客观赋权 → TOPSIS 综合排序 → 场景偏好组合赋权 → 成本效益与 Pareto 分析 → 熵权法和权重扰动检验。

2 数据、假设与符号

2.1 数据边界与来源

统一截面为 2026-08-17。Benchmark 原始表含 148 条记录，模型元数据表含 9 条模型记录及 79 条逐字段证据，效率表含 9 条模型记录及 27 条逐指标证据。核心来源及其用途如下。

来源类型	主要来源	用途
同平台横向评测	Artificial Analysis 模型页与榜单	固定版本、推理配置和效率口径
厂商官方资料	Kimi、OpenAI、Anthropic、Z.ai 官方模型/定价页	模型版本、API 价格、上下文与能力说明
Benchmark 官方资料	HLE、Agents Last Exam 等官方榜单/论文	核验指标定义和原始成绩
仓库证据索引	data/sources/*.csv	保存 URL、检索日期、口径和字段级出处

最终研究池含 6 个模型。Gemini 3.1 Pro Preview 因 preview 状态及严格可比覆盖不足排除；DeepSeek V4 Pro 0813、Qwen3.8 2.4T A95B 距截止日仅 4 天和 5 天且分项数据不足，保留原始记录但不进入正式模型池。来源 URL 在第 11 节列出，逐字段证据以仓库索引为准。

2.2 基本假设

1. 固定来源 cohort 内的成绩可横向比较，但不同厂商的最高 reasoning effort 不代表相同计算预算。
2. 公布成绩只在本数据截面有效；滚动效率数据只代表检索窗口。
3. 9 项能力指标均为效益型指标，数值越大表示该项能力越强。
4. 缺失值不等于零。GLM-5.2 在冻结 cohort 中缺少 5 项核心成绩，均不插补，也不进入要求完整矩阵的 TOPSIS 主排名。

设模型为 $i = 1, \dots, m$ ，指标为 $j = 1, \dots, n$ ，原始值为 x_{ij} ，标准化值为 z_{ij} ，指标权重为 w_j 。

3 数据清洗与指标筛选

所有核心记录均固定 benchmark 版本、测试设置及来源，形成 6×9 宽表和 54 行长表。百分制和 Elo 不直接求和，而是在建模阶段逐指标极差标准化：

$$z_{ij} = \frac{x_{ij} - \min_i x_{ij}}{\max_i x_{ij} - \min_i x_{ij}}.$$

候选指标先满足覆盖率不低于 80%、有效样本标准差非零，再检查相关性。9 项指标覆盖率均为 83.3% 或 100%。Spearman 绝对值不低于 0.9 的组合有两对：GPQA Diamond—MMM—Pro (0.9211) 与 SciCode—CharXiv RQ (0.9747)。但共同观测仅 5 个，且分别刻画文本科学推理与多模态推理、科学编程与研究文档理解，机械删除会损失题目所需的场景语义，因此保留全部 9 项，并将相关性风险纳入稳健性分析。




Figure 1: Pearson 相关系数矩阵

4 CRITIC—TOPSIS 综合评价

4.1 CRITIC 权重

CRITIC 同时利用指标的对比强度和冲突性。令标准化指标 j 的标准差为 σ_j ，指标间 Pearson 相关系数为 r_{jk} ，则

$$C_j = \sigma_j \sum_{k=1}^n (1 - r_{jk}), \quad w_j = \frac{C_j}{\sum_j C_j}.$$

权重最高的三项为 HLE-Full (0.2013)、OmniDocBench (0.1483) 和 AA-LCR (0.1270)，最低为 SciCode (0.0674)。这些权重反映当前样本中的差异性与冲突性，不代表永久的重要性判断。




Figure 2: CRITIC 指标权重

4.2 TOPSIS 排名与 GLM 局部对照

构造加权矩阵 $v_{ij} = w_j z_{ij}$ ，正、负理想解为各列最大值和最小值。模型到理想解的欧氏距离为 D_i^+ 、 D_i^- ，贴近度为

$$S_i = \frac{D_i^-}{D_i^+ + D_i^-}.$$

主排名只使用 9 项成绩完整的 5 个模型：

排名	模型	TOPSIS 得分
1	Claude Fable 5	0.7254
2	Kimi K3	0.5933
3	GPT-5.6 Sol	0.5178
4	GPT-5.5	0.4410
5	Claude Opus 4.8	0.3902




Figure 3: 综合排名

GLM-5.2 的同口径局部成绩不参与总体赋权和排名，但可逐项定位：

同口径指标	GLM-5.2	6 模型局部名次	局部领先者	与领先者差值
GPQA Diamond	91.2	5	GPT-5.6 Sol	2.9
AA-LCR	71.3	4	Kimi K3	3.4
SciCode	50.5	6	Claude Fable 5	9.7
GDPval-AA v2	1510	5	Claude Fable 5	237

Z.ai 官方另报 HLE 40.5 (with tools 为 54.7)，但来源与测试 cohort 不同，只作为补充证据，不替换冻结矩阵中的 NA。四项视觉指标对纯文本 GLM-5.2 不适用。该做法避免把“未评价”误写成“低性能”。

4.3 Kimi K3 优势与短板

Kimi K3 在 AA-LCR 和 OmniDocBench 排名第一，在 SciCode、MMMU-Pro、CharXiv RQ 排名第二，体现出长文本推理、文档理解和科研材料处理优势。其 HLE-Full 标准化得分仅 0.1765，在 5 个完整模型中第 4，是最明确的短板；

GLM-5.2 四项可比文本能力局部定位




Figure 4: GLM-5.2 同口径局部对照

GPQA Diamond 与 GDPval-AA v2 位于中游。因此 Kimi 的竞争力集中于长文本和文档场景，而极高难度开放推理仍有提升空间。




Figure 5: Kimi K3 分项雷达图

5 三类场景评价

为体现应用偏好，本文为每个场景给出总和为 1 的主观优先权重 a_{sj} ，再与 CRITIC 权重等比例组合：

$$w_{sj}^* = 0.5w_j + 0.5a_{sj}.$$

科研场景的前三项组合权重为 AA-LCR 0.1885、HLE-Full 0.1607、OmniDocBench 0.1341；日常对话为 HLE-Full 0.1607、GDPval-AA v2 0.1584、OmniDocBench 0.1241；代码开发为 SciCode 0.2337、HLE-Full 0.1407、GDPval-AA v2 0.1184。由此得到完整场景得分：

模型	科研长文本	日常对话	代码开发
Claude Fable 5	0.6471 (2)	0.7208 (1)	0.7722 (1)
Kimi K3	0.6547 (1)	0.6343 (2)	0.6840 (2)
GPT-5.6 Sol	0.5703 (3)	0.6024 (3)	0.5838 (3)
GPT-5.5	0.5276 (4)	0.4392 (4)	0.4896 (4)
Claude Opus 4.8	0.3147 (5)	0.3431 (5)	0.3384 (5)




Figure 6: 三类场景得分与排名

Kimi 在科研长文本场景由综合第 2 升至第 1，机制是其 AA-LCR、OmniDocBench 优势在该场景被放大；在日常与代码场景仍为第 2。对每个指标权重分别乘 0.8、0.9、1.1、1.2 并归一化，共形成每场景 36 组扰动：Kimi 的科研名次为 1—2，保持第一的概率为 88.89%，最小 Kendall $\tau = 0.8$ ；日常与代码名次始终为 2， $\tau = 1$ 。

6 性能—成本与工程效率

6.1 标准负载与 Pareto 前沿

定义标准工作负载为 100 万输入 token 与 20 万输出 token，使用标准 API 单价：

$$Cost_i = P_{in,i} + 0.2P_{out,i}.$$




Figure 7: Kimi K3 场景表现

模型	标准负载成本/美元	综合得分	性能/美元	Pareto 前沿
Kimi K3	6	0.5933	0.0989	是
GPT-5.5	6	0.4410	0.0735	否
Claude Opus 4.8	10	0.3902	0.0390	否
GPT-5.6 Sol	11	0.5178	0.0471	否
Claude Fable 5	20	0.7254	0.0363	是




Figure 8: 性能—成本 Pareto 前沿

Kimi K3 与 Claude Fable 5 构成 Pareto 前沿。预算为 6、10、12、16 美元时，“预算内综合得分最高”均推荐 Kimi K3；预算达到 20 美元时推荐 Claude Fable 5。GLM-5.2 标准负载成本为 1.918 美元，但因能力覆盖不足，不能进入该推荐规则。

6.2 工程效率与计算能耗边界

仅对配置兼容的 Kimi K3、GPT-5.6 Sol、Claude Opus 4.8、GPT-5.5 比较 TTFT、输出速度和总延迟。将成本型指标正向化后等权平均得到工程效率，再按 70% 综合性能与 30% 工程效率计算部署分：Kimi K3 为 0.5862（第 1），GPT-5.5 为 0.5582（第 2），Claude Opus 4.8 为 0.5010（第 3），GPT-5.6 Sol 为 0.4309（第 4）。Claude Fable 5 记录含 Opus fallback，GLM-5.2 为第三方部署，均不作硬比较。

题目同时要求考虑计算消耗。经逐模型审计，当前公开数据均没有同硬件、同批量、同精度和同输出长度下的功率、焦




Figure 9: 性能与工程效率组合

耳/token 或 kWh 记录，因此 `energy_data_available=False`。参数量不能代替推理时激活参数，延迟和吞吐也不能代替功率，本文不据此估算能耗。当前可回答的是直接 API 落地成本和兼容配置下的时间效率；若后续获得统一测试，应记录 GPU 型号与数量、量化精度、batch、输入/输出长度、平均功率和总时间，并以 J/token 或 kWh/任务加入成本函数。

7 稳健性与规律分析

熵权法得到的完整模型排名与 CRITIC 完全一致。对 9 个 CRITIC 权重分别进行 $\pm 10\%$ 、 $\pm 20\%$ 单因素扰动，共 36 组；Claude Fable 5、Kimi K3、GPT-5.6 Sol 始终保持第 1、2、3，GPT-5.5 与 Claude Opus 4.8 仅出现一次相邻换位，最小 Kendall $\tau = 0.8$ 。场景权重的独立扰动结果见第 5 节。

对 5 个完整模型拟合探索性关系

$$Performance = 0.1994 + 0.1481 \ln(Cost),$$

得到 $R^2 = 0.3147$ 、调整 $R^2 = 0.0862$ 、RMSE=0.0978。样本仅为 5，故只能描述“价格与性能存在弱正相关、价格解释力有限”，不能作因果推断。

8 模型评价与局限

本方法的优点是来源可追溯、比较 cohort 固定、缺失处理保守、权重与排序可复现，并通过场景、成本和稳健性形成闭环。主要局限如下：

1. 最终研究池仅 6 个模型，主排名完整样本为 5 个，相关系数与回归不宜外推。
2. 核心横向表虽设置一致，但仍可能存在厂商报告偏差；滚动平台数据也只代表截面。

3. GLM-5.2 仅有 4 项同口径能力数据，当前不能给出公平总排名。
4. 效率子样本只有 4 个兼容配置，且无法覆盖 Claude Fable 5 和 GLM-5.2。
5. 价格未纳入区域、缓存命中、batch、长上下文阶梯或峰谷套餐，预算结论只对应本文标准负载。
6. 同口径计算能耗数据完全缺失，当前不能报告能耗排名或把能耗折算为货币成本。
7. 场景主观权重虽透明，仍应在专家问卷或团队评审后更新。

9 结论

在不插补缺失数据的前提下，Claude Fable 5 获得通用综合评价第一，Kimi K3 第二。Kimi 的核心优势是长文本、文档理解和科研材料处理，其主要短板是 HLE-Full 所代表的极高难度开放推理；在科研长文本场景中升至第一。标准 API 负载下，Kimi 与 Claude Fable 5 构成 Pareto 前沿，Kimi 在中低预算区间和兼容工程效率子样本中具有更好的落地平衡。主排名与绝大多数场景结论经替代赋权和扰动检验后稳定。所有结论均限定在本数据截面、固定 cohort、完整样本和已声明的成本口径内。

10 复现说明

在仓库根目录安装 requirements.txt 后运行：

```
python scripts/run_pipeline.py
python scripts/run_q1.py
python scripts/run_glm_supplement.py
python scripts/run_q2.py
python scripts/run_q3.py
python scripts/validate_q1.py
python scripts/validate_q2_q3.py
python -m unittest discover tests -v
python scripts/build_paper.py
python scripts/validate_paper.py
```

原始题面保存在 references/problem/TJMML_B.pdf, 逐项符合性矩阵在 docs/problem_compliance_matrix.md; 中间结果分别位于 results/phase3/ 至 results/phase7/ 以及 results/q1/ 至 results/q3/。

11 数据来源与可追溯性

- Kimi K3 官方介绍: <https://www.kimi.com/blog/kimi-k3>
- Kimi API 说明: <https://www.kimi.com/help/kimi-api/api-troubleshooting>
- OpenAI 模型文档: <https://developers.openai.com/api/docs/models/gpt-5.6-sol>
- OpenAI API 定价: <https://platform.openai.com/docs/pricing/>
- Anthropic 模型与定价: <https://platform.claude.com/docs/en/about-claude/pricing>
- Z.ai GLM-5.2 文档: <https://docs.bigmodel.cn/cn/guide/models/text/glm-5.2>
- Z.ai API 定价: <https://open.bigmodel.cn/pricing>
- GLM-5.2 官方模型卡: <https://huggingface.co/zai-org/GLM-5.2>
- Artificial Analysis: <https://artificialanalysis.ai/>

以上列表提供可阅读入口；用于计算的每一个有效字段仍以 data/sources/benchmark_sources.csv、meta-data_sources.csv、efficiency_sources.csv 中记录的精确 URL、检索日期和口径说明为准。